

Rapport de projet

Analyse Big Data Serverless des Données de
Trafic Télécom en Afrique

Étudiantes: Farimata Wade – Khadidiatou Diallo

École: ISI Dakar

Cours: AWS Academy Cloud Foundations 2025-2026

Responsable pédagogique: M. LAM Sabarane

Date: Mars 2026

1. Introduction

Les opérateurs de télécommunications africains génèrent chaque jour des centaines de millions de transactions: appels voix, SMS, navigation internet et transferts Mobile Money. L'analyse de ces données massives est devenue un enjeu stratégique majeur pour optimiser la couverture réseau, détecter les fraudes et comprendre les comportements des clients.

Ce projet propose une pipeline d'analyse Big Data entièrement serverless sur Amazon Web Services (AWS), couvrant l'ensemble du cycle de vie des données: de l'ingestion des données brutes jusqu'aux requêtes analytiques interactives. La solution repose sur trois services AWS principaux — Amazon S3, AWS Glue et Amazon Athena sans nécessiter la gestion d'aucun serveur.

L'objectif est de démontrer qu'il est possible de construire une infrastructure d'analyse de données télécom professionnelle, économique et scalable, adaptée au contexte africain.

2. Architecture de la solution

L'architecture mise en place suit le modèle Data Lake serverless sur AWS. Elle est composée de six services interconnectés:

Amazon S3, couche de stockage: Le bucket african-traffic-telecom constitue le data lake central du projet. Il est organisé en trois zones: raw/ (données brutes CSV), processed/ (données Parquet transformées) et results/ (résultats des requêtes Athena).

AWS Glue Crawler, catalogage automatique: Le crawler crawler-telecom parcourt automatiquement le bucket S3 et crée la table raw_raw dans la base de données telecom_bd. Il détecte le schéma des données sans intervention manuelle.

AWS Glue ETL Job, transformation des données: Le job etl-telecom-csv-parquet lit les données CSV depuis raw/, les nettoie, les convertit au format Parquet avec compression Snappy et les écrit dans processed/. Ce format réduit de 8 fois le volume de données analysées.


Amazon Athena, analyse SQL interactive: Athena permet d'exécuter des requêtes SQL directement sur les fichiers S3 sans serveur de base de données. Le coût est de 5\$ par téraoctet scanné, réduit considérablement grâce au format Parquet.

IAM, sécurité et contrôle d'accès: Le rôle AWSGlueServiceRole-lab définit les permissions accordées à Glue pour accéder à S3. La politique AmazonS3FullAccess permet la lecture et l'écriture dans le bucket.

Amazon CloudWatch, surveillance: CloudWatch enregistre automatiquement les logs et métriques des jobs Glue, permettant de diagnostiquer les erreurs et surveiller les performances.

Pipeline Big Data Serverless — Trafic Télécom Afrique

ISI Dakar — AWS Academy Cloud Foundations 2025-2026



3. Génération du dataset

Le dataset utilisé dans ce projet est un jeu de données synthétiques généré à l'aide d'un script Python. Cette approche a été choisie car les données télécom réelles sont confidentielles et non accessibles publiquement.

Caractéristiques du dataset

Le script génère 50 000 transactions télécom réalistes couvrant la période de janvier à mars 2024, pour 5 pays africains et 5 opérateurs. Chaque transaction contient 10 colonnes:

Colonne	Description	Exemple
msisdn	Numéro client anonymisé	SN_004821
date_heure	Horodatage de l'événement	2024-01-15 14:32:11
pays	Pays de l'événement	Senegal
opérateur	Opérateur télécom	Orange
type_evenement	Type de transaction	CALL
duree_secondes	Durée en secondes	187
volume_mb	Volume data consommé (Mo)	0.0
montant_xof	Montant en francs CFA	350
statut	Résultat de la transaction	SUCCESS
antenne_id	Identifiant de l'antenne	ANT_DKR_042

Répartition des événements

Type d'événement	Proportion	Justification
DATA	35%	Service le plus utilisé en Afrique
CALL	30%	Appels voix traditionnels
SMS	20%	Messages courts
MOMO	15%	Mobile Money en croissance

[Amazon S3](#) > [Compartiments](#) > [african-traffic-isi-dakar](#) > [raw/](#) > [telecom/](#) > [year=2024/](#)

year=2024/ [Copier l'URI S3](#)

[Objets](#) [Propriétés](#)

Objets (3) [Copier l'URI S3](#) [Copier l'URL](#) [Télécharger](#) [Ouvrir](#) [Supprimer](#) [Actions](#) [Créer un dossier](#) [Charger](#)

Les objets sont les entités fondamentales stockées dans Amazon S3. Vous pouvez utiliser [l'inventaire Amazon S3](#) pour obtenir une liste de tous les objets de votre compartiment. Pour que d'autres personnes puissent accéder à vos objets, vous devez leur accorder explicitement des autorisations. [En savoir plus](#)

☐	Nom	Type	Dernière modification	Taille	Classe de stockage
☐	month=01/	Dossier	-	-	-
☐	month=02/	Dossier	-	-	-
☐	month=03/	Dossier	-	-	-

4. Data Lake Amazon S3


Amazon S3 (Simple Storage Service) constitue la fondation du projet. Il joue le rôle de data lake, un espace de stockage centralisé qui contient toutes les données du projet, brutes et transformées.

Structure du bucket S3

```
african-traffic-telecom/
├── raw/
│   └── telecom/
│       └── year=2024/
│           ├── month=01/day=01/telecom_data.csv
│           ├── month=02/day=01/telecom_data.csv
│           └── month=03/day=01/telecom_data.csv
├── processed/
│   ├── pays=Burkina_Faso/type_evenement=CALL/
│   ├── pays=Cote_Ivoire/type_evenement=DATA/
│   ├── pays=Senegal/type_evenement=MOMO/
│   └── ...
├── results/
├── scripts/
│   └── glue_etl_job.py
```

Le partitionnement Hive

Le partitionnement Hive est une technique qui organise les données en sous-dossiers selon des colonnes clés. Par exemple `year=2024/month=01/` indique à Athena que ce dossier contient uniquement les données de janvier 2024. Quand une requête filtre sur `month=01`, Athena ne lit que ce dossier, ce qui réduit considérablement les données scannées et donc le coût.



5. AWS Glue Crawler

Un Crawler est un robot qui parcourt automatiquement une source de données (ici un bucket S3) et crée une table dans le Glue Data Catalog. Cette table contient les métadonnées des fichiers : noms des colonnes, types de données, localisation des fichiers et partitions disponibles.

Configuration du Crawler

Paramètre	Valeur
Nom	crawler-telecom
Source S3	s3://african-traffic-telecom/raw/
Base de données cible	telecom_bd
Préfixe des tables	raw
Rôle IAM	AWSGlueServiceRole-lab
Planification	À la demande

Résultat du Crawler

Après exécution, le crawler a automatiquement créé la table `raw_raw` dans la base de données `telecom_bd` avec les 10 colonnes correctement détectées.

Colonne	Type détecté
msisdn	string
date_heure	string
pays	string
opérateur	string
type_evenement	string
duree_secondes	int
volume_mb	double
montant_xof	int
statut	string
antenne_id	string

aws

Rechercher

[Alt+S]

Posez une question à Amazon Q

Europe (Stockholm)

fary2001 (7335-0895-6662)

fary2001

AWS Glue

Crawlers

crawler-telecom

Getting started

ETL jobs

Visual ETL

Notebooks

Job run monitoring

Data Catalog tables

Data connections

Workflows (orchestration)

Zero-ETL integrations

Data Catalog

Data Integration and ETL

Legacy pages

What's New

Documentation

AWS Marketplace

One crawler successfully created

The following crawler is now created: "crawler-telecom"

crawler-telecom

Last updated (UTC)
March 25, 2026 at 21:56:11

Run crawler

Edit

Delete

Crawler properties

Name crawler-telecom	IAM role AWSGlueServiceRole-lab	Database telecom_bd	State READY
Description -	Security configuration -	Lake Formation configuration -	Table prefix raw_
Maximum table threshold -			

Advanced settings

Crawler runs | Schedule | Data sources | Classifiers | Tags

Crawler runs (0)

Stop run | View CloudWatch logs | View run details

AWS Glue > Tables > raw_raw

Data Catalog tables

Data connections

Workflows (orchestration)

Zero-ETL integrations [New](#)

▼ Data Catalog

Catalogs

Databases

[Tables](#)

Stream schema registries

Schemas

Connections

Crawlers

Classifiers

Catalog settings

► Data Integration and ETL

► Legacy pages

Schema (14)

View and manage the table schema.

Q

Filter schemas

<

1

>

#	Column name	Data type	Partition key	Comment
1	msisdn	string	-	-
2	date_heure	string	-	-
3	pays	string	-	-
4	opérateur	string	-	-
5	type_evenement	string	-	-
6	duree_secondes	bigint	-	-
7	volume_mb	double	-	-
8	montant_xof	bigint	-	-
9	statut	string	-	-
10	antenne_id	string	-	-

6. Job ETL Glue — Transformation CSV vers Parquet

ETL signifie Extract, Transform, Load. C'est le processus qui permet de prendre des données brutes, de les nettoyer et de les convertir dans un format optimisé pour l'analyse.

Configuration du job ETL

Paramètre	Valeur
Nom	etl-telecom-csv-parquet
Script	s3://african-traffic-telecom/scripts/glue_etl_job.py
Rôle IAM	AWSGlueServiceRole-lab
Version Glue	3.0
Workers	2 x G.1X
Langage	Python

Les transformations appliquées

- Lecture des données CSV via le Glue Data Catalog
- Suppression des lignes contenant des valeurs nulles (dropna())
- Normalisation des types : duree_secondes → INTEGER, volume_mb → DOUBLE, montant_xof → INTEGER
- Écriture en Parquet avec compression Snappy
- Partitionnement par pays et type_evenement

The screenshot displays the AWS Glue console interface. On the left is a navigation sidebar with categories like Catalogs, Databases, Tables, Stream schema registries, Schemas, Connections, Crawlers, Classifiers, and Catalog settings. The main panel shows the configuration for the job 'etl-telecom-csv-parquet', last modified on 25/03/2026 at 23:39:05. It includes tabs for Script, Job details, Runs, Data quality, Schedules, Version Control, and Upgrade analysis. The 'Runs' tab is active, showing 'Job runs (1/2)' with a 'View details' button and a 'Stop job run' button. Below this, the 'Run details' tab is selected, displaying a table of run metrics for a specific run ID: c5ca9a5efbff176bfd51f9152ed59b3799312bc. The table includes columns for Run status (Succeeded), Start-up time (6 seconds), Max capacity (2 DPU's), Number of workers (2), Retry attempt number, Execution time, Execution class, and Timeout.

Run ID	Run status	Start-up time	Max capacity	Number of workers	Retry attempt number	Execution time	Execution class	Timeout
c5ca9a5efbff176bfd51f9152ed59b3799312bc	Succeeded	6 seconds	2 DPU's	2				

7. Requêtes Athena analytiques

Amazon Athena est un service de requêtes SQL interactives qui permet d'analyser directement des données stockées dans S3, sans serveur à gérer. Le coût est de 5\$ par téraoctet scanné.

Requête 1: Top 10 antennes par volume data

```
SELECT antenne_id, ROUND(SUM(volume_mb), 2) as volume_total_mb
FROM telecom_parquet WHERE type_evenement = 'DATA'
GROUP BY antenne_id ORDER BY volume_total_mb DESC LIMIT 10;
```

Résultat: L'antenne ANT_OUA_043 est la plus sollicitée avec 8 626 Mo traités.

Rechercher des lignes				< 1 >		⚙	
#	▼	antenne_id	▼	volume_total_mb	▼		
1		ANT_OUA_043		8626.82			
2		ANT_ABJ_125		8137.82			
3		ANT_CKY_123		7807.34			
4		ANT_CKY_120		7801.34			
5		ANT_CKY_082		7769.48			
6		ANT_ABJ_169		7717.99			
7		ANT_DKR_124		7657.29			
8		ANT_CKY_027		7549.93			
9		ANT_DKR_192		7495.24			
10		ANT_CKY_155		7418.26			

Requête 2: Revenue total par pays et par opérateur

```
SELECT pays, operateur, SUM(montant_xof) as revenue_total_xof
FROM telecom_parquet WHERE statut = 'SUCCESS'
GROUP BY pays, operateur ORDER BY pays, revenue_total_xof DESC;
```

Résultat: MTN domine les revenus au Mali (78M XOF) et en Guinée (76M XOF).

✓ Terminé

Temps en file d'attente: 59 ms

Durée d'exécution: 772 ms

Données analysées: 220.42 KB

Résultats (25)

 Copier

 Télécharger les résultats CSV

 Rechercher des lignes

< 1 > 

#	pays	opérateur	revenue_total_xof
1	Burkina_Faso	Orange	74716532
2	Burkina_Faso	Free	73567621
3	Burkina_Faso	Wave	70205268
4	Burkina_Faso	MTN	69668722
5	Burkina_Faso	Moov	68887031
6	Cote_Ivoire	Orange	76225919
7	Cote_Ivoire	MTN	68361832

Requête 3: Taux d'échec par type d'événement

```
SELECT type_evenement, COUNT(*) as total,  
ROUND(SUM(CASE WHEN statut='FAILED' THEN 1 ELSE 0 END)*100.0/COUNT(*),2) as  
taux_echec_pct  
FROM telecom_parquet GROUP BY type_evenement;
```

Résultat: Taux d'échec homogène autour de 10% pour tous les types d'événements.

Résultats de la requête

Statistiques de la requête

Terminé

Temps en file d'attente: 111 ms

Durée d'exécution: 880 ms

Données analysées: 12.48 KB

Résultats (4)

Copier

Télécharger les résultats CSV

Rechercher des lignes

< 1 > ⚙

#	type_evenement	total	total_echecs	taux_echec_pct
1	CALL	14817	1500	10.12
2	SMS	9912	996	10.05
3	DATA	17775	1777	10.0
4	MOMO	7496	744	9.93

Requête 4 — Volume Mobile Money par heure

```
SELECT HOUR(CAST(date_heure AS TIMESTAMP)) as heure,
COUNT(*) as nb_transactions, SUM(montant_xof) as volume_total_xof
FROM telecom_parquet WHERE type_evenement = 'MOMO'
GROUP BY HOUR(CAST(date_heure AS TIMESTAMP)) ORDER BY heure;
```

Résultat : Le Mobile Money est actif 24h/24 avec environ 310 transactions par heure.

Terminé Temps en file d'attente: 118 ms Durée d'exécution: 625 ms Données analysées: 100.37 KB			
Résultats (24) Copier Télécharger les résultats CSV		Rechercher des lignes < 1 > ⚙️	
#	heure	nb_transactions	volume_total_xof
1	0	338	82158824
2	1	306	77852439
3	2	310	70498041
4	3	308	76338304
5	4	310	76218744
6	5	302	76726310
7	6	305	82063645

Requête 5 — Distribution des appels par durée

```
SELECT CASE WHEN duree_secondes < 60 THEN 'Moins de 1 min'
  WHEN duree_secondes BETWEEN 60 AND 300 THEN '1 à 5 min'
  ELSE 'Plus de 5 min' END as categorie_duree,
COUNT(*) as nb_appels FROM telecom_parquet
WHERE type_evenement = 'CALL' GROUP BY 1 ORDER BY nb_appels DESC;
```

Résultat : 50% des appels durent plus de 5 minutes, 41% entre 1 et 5 minutes.

Résultats de la requête

Statistiques de la requête

Terminé

Temps en file d'attente: 117 ms

Durée d'exécution: 732 ms

Données analysées: 45.73 KB

Résultats (3)

Copier

Télécharger les résultats CSV

Rechercher des lignes

<

1

>

#	categorie_duree	nb_appels	pourcentage
1	Plus de 5 min	7434	50.17
2	1 à 5 min	6102	41.18
3	Moins de 1 min	1281	8.65

Requête 6 — Évolution quotidienne des événements

```
SELECT DATE(CAST(date_heure AS TIMESTAMP)) as date_jour,  
COUNT(*) as nb_evenements FROM telecom_parquet  
GROUP BY DATE(CAST(date_heure AS TIMESTAMP)) ORDER BY date_jour;
```

Résultat: Moyenne stable de 550 événements par jour sur la période analysée.

Résultats de la requête

Statistiques de la requête

Terminé

Temps en file d'attente: 117 ms Durée d'exécution: 732 ms Données analysées: 45.73 KB

Résultats (3)

Copier

Télécharger les résultats CSV

Rechercher des lignes

< 1 > ⚙

#	▼	categorie_duree	▼	nb_appels	▼	pourcentage	▼
1		Plus de 5 min		7434		50.17	
2		1 à 5 min		6102		41.18	
3		Moins de 1 min		1281		8.65	

Requête 7 — Détection de fraude Mobile Money

```
SELECT msisdn, DATE(CAST(date_heure AS TIMESTAMP)) as date_jour,  
COUNT(*) as nb_transactions FROM telecom_parquet  
WHERE type_evenement='MOMO' AND statut='SUCCESS'  
GROUP BY msisdn, 2 HAVING COUNT(*) > 10;
```

Résultat: Aucun cas de fraude détecté(comportement normal des utilisateurs).

Résultats de la requête

Statistiques de la requête

Terminé

Temps en file d'attente: 60 ms

Durée d'exécution: 740 ms

Données analysées: 156.99 KB

Résultats (0)

Copier

Télécharger les résultats CSV

Rechercher des lignes

< 1 >

#

msisdn

date_jour

nb_transactions_momo

montant_total_xof

Aucun résultat

Exécuter une requête pour afficher les résultats

Requête 8 — Opérateur le plus fiable par pays

```
SELECT pays, operateur,
ROUND(SUM(CASE WHEN statut='SUCCESS' THEN 1 ELSE 0 END)*100.0/COUNT(*),2) as
taux_succes_pct
FROM telecom_parquet GROUP BY pays, operateur ORDER BY pays, taux_succes_pct
DESC;
```

Résultat: Orange est le plus fiable au Burkina Faso (90.37%) et au Sénégal (90.20%).

Terminé

Temps en file d'attente: 56 ms

Durée d'exécution: 734 ms

Données analysées: 37.01 KB

Résultats (25)

Copier

Télécharger les résultats CSV

Rechercher des lignes

< 1 >

#	pays	operateur	total_transactions	taux_succes_pct
1	Burkina_Faso	Orange	2025	90.37
2	Burkina_Faso	Moov	1975	90.08
3	Burkina_Faso	Free	1987	89.93
4	Burkina_Faso	MTN	2001	89.86
5	Burkina_Faso	Wave	1956	89.67
6	Cote_Ivoire	MTN	1955	90.54
7	Cote_Ivoire	Moov	1981	90.36

8. Comparaison CSV vs Parquet

Le choix du format de stockage a un impact direct sur les performances des requêtes et sur le coût d'utilisation d'Athena.

Différences fondamentales

Critère	CSV	Parquet
Orientation	Ligne	Colonne
Compression	Aucune	Snappy
Lisibilité	Texte brut	Binaire optimisé
Taille sur disque	Grande	Réduite (~8x)
Vitesse de lecture	Lente	Rapide
Coût Athena	Élevé	Faible

Résultats mesurés sur notre dataset

Métrique	CSV	Parquet	Gain
Lignes retournées	50 000	50 000	egaux
Temps d'exécution	629 ms	375 ms	1.7x plus rapide
Données scannées	3.91 MB	463 KB	8x moins
Coût estimé (\$5/TB)	\$0.0000196	\$0.0000023	8x moins cher

9. Conclusions stratégiques

Conclusion 1: La Data mobile est le service dominant

Analyse: L'analyse de la distribution des événements révèle que la consommation de données internet représente 35% de toutes les transactions, devant les appels voix (30%), les SMS (20%) et le Mobile Money (15%). La requête sur l'évolution quotidienne montre une moyenne stable de 200 événements DATA par jour.

Recommandation: Les opérateurs africains devraient prioriser l'investissement dans l'infrastructure réseau DATA (4G/5G). Le développement de forfaits data illimités ou à prix réduit pourrait attirer davantage de clients et augmenter les revenus.

Conclusion 2 — Les appels sont majoritairement longs

Analyse: 50% des appels durent plus de 5 minutes et 41% entre 1 et 5 minutes. Seulement 8.65% des appels durent moins d'une minute. Cela indique que les utilisateurs africains utilisent le téléphone pour des conversations longues et substantielles.

Recommandation: Les opérateurs devraient proposer des forfaits voix illimités ou des tarifs dégressifs pour les longues communications. Des offres famille avec appels illimités entre abonnés pourraient générer de la fidélisation.

Conclusion 3: La fiabilité des réseaux est perfectible

Analyse: Tous les opérateurs tournent autour de 90% de taux de succès, avec des variations faibles. Un taux d'échec de 10% représente 5 000 transactions échouées sur notre dataset — des millions à l'échelle réelle.

Recommandation: Les opérateurs devraient investir dans l'amélioration de la qualité réseau pour dépasser le seuil de 95% de taux de succès. Une amélioration de 5% sur le Mobile Money pourrait représenter des millions de francs CFA supplémentaires.

10. Conclusion générale

Ce projet a démontré qu'il est possible de construire une pipeline d'analyse Big Data professionnelle, économique et entièrement serverless sur AWS, sans gérer aucun serveur ni infrastructure complexe.

Ce qui a été réalisé

- Génération d'un dataset synthétique de 50 000 transactions réalistes représentant 5 pays et 5 opérateurs africains
- Construction d'un data lake structuré sur Amazon S3 avec partitionnement Hive
- Catalogage automatique des données via AWS Glue Crawler
- Transformation des données CSV en Parquet avec compression Snappy, réduisant de 8 fois le volume scanné
- Exécution de 8 requêtes analytiques sur Amazon Athena révélant des insights business concrets
- Création d'une vue consolidée des KPIs principaux

Perspectives d'amélioration

- Automatisation avec AWS Step Functions pour orchestrer la pipeline
- Visualisation avec Amazon QuickSight pour des tableaux de bord interactifs
- Alertes CloudWatch pour détecter les anomalies en temps réel
- Ingestion temps réel avec Amazon Kinesis
- Machine Learning avec Amazon SageMaker pour la détection avancée de fraude

Ce projet illustre parfaitement comment le cloud computing démocratise l'accès aux technologies Big Data. Des analyses qui nécessitaient autrefois des équipes d'ingénieurs et des infrastructures coûteuses sont aujourd'hui accessibles grâce à AWS.